



human-harmful (n=750)    safe, benign prompt (n=1023)    safe, harmful prompt (n=1227)